

✓ Практическое задание №1

Установка необходимых пакетов:

```
!pip install -q tqdm
!pip install --upgrade --no-cache-dir gdown
```

```
Requirement already satisfied: gdown in /usr/local/lib/python3.12/dist-packages (5.2.0)
Requirement already satisfied: beautifulsoup4 in /usr/local/lib/python3.12/dist-packages (from gdown) (4.13.5)
Requirement already satisfied: filelock in /usr/local/lib/python3.12/dist-packages (from gdown) (3.20.0)
Requirement already satisfied: requests[socks] in /usr/local/lib/python3.12/dist-packages (from gdown) (2.32.4)
Requirement already satisfied: tqdm in /usr/local/lib/python3.12/dist-packages (from gdown) (4.67.1)
Requirement already satisfied: soupsieve>1.2 in /usr/local/lib/python3.12/dist-packages (from beautifulsoup4->gdown) (2.8)
Requirement already satisfied: typing-extensions>=4.0.0 in /usr/local/lib/python3.12/dist-packages (from beautifulsoup4->gdown) (4.13.5)
Requirement already satisfied: charset-normalizer<4,>=2 in /usr/local/lib/python3.12/dist-packages (from requests[socks]->gdown) (3.2.0)
Requirement already satisfied: idna<4,>=2.5 in /usr/local/lib/python3.12/dist-packages (from requests[socks]->gdown) (3.11)
Requirement already satisfied: urllib3<3,>=1.21.1 in /usr/local/lib/python3.12/dist-packages (from requests[socks]->gdown) (2.2.3)
Requirement already satisfied: certifi>=2017.4.17 in /usr/local/lib/python3.12/dist-packages (from requests[socks]->gdown) (2025.1.1)
Requirement already satisfied: PySocks!=1.5.7,>=1.5.6 in /usr/local/lib/python3.12/dist-packages (from requests[socks]->gdown) (1.7.1)
```

Монтирование Вашего Google Drive к текущему окружению:

```
from google.colab import drive
drive.mount('/content/drive', force_remount=True)
```

Константы, которые пригодятся в коде далее, и ссылки (gdrive идентификаторы) на предоставляемые наборы данных:

```
EVALUATE_ONLY = False
TEST_ON_LARGE_DATASET = True
TISSUE_CLASSES = ('ADI', 'BACK', 'DEB', 'LYM', 'MUC', 'MUS', 'NORM', 'STR', 'TUM')
DATASETS_LINKS = {
    'train': '1XtQzVQ5XbrfxpLHJUL0XBGJ5U7CS-cLi',
    'train_small': '1qd45xXfDwdZjktLFwQb-et-mAaFeCzOR',
    'train_tiny': '1I-2Z0uXld4QwhZQQ1tp817Kn3J0Xgbui',
    'test': '1RfPou3pFKpuHDJZ-D9XDFzgvwpUBF1Dr',
    'test_small': '1wbRsog0n7uG1HIPGLhyN-PMET2kdQ21I',
    'test_tiny': '1viiB0s041CNsAK4itvX8PNYthJ-MDnQc'
}
```

Импорт необходимых зависимостей:

```
from pathlib import Path
import numpy as np
from typing import List
from tqdm.notebook import tqdm
from time import sleep
from PIL import Image
import IPython.display
from sklearn.metrics import balanced_accuracy_score
import gdown

%matplotlib inline
```

✓ Класс Dataset

Предназначен для работы с наборами данных, обеспечивает чтение изображений и соответствующих меток, а также формирование пакетов (батчей).

```
class Dataset:

    def __init__(self, name):
        self.name = name
        self.is_loaded = False
        url = f"https://drive.google.com/uc?export=download&confirm=pbef&id={DATASETS_LINKS[name]}"
        output = f'{name}.npz'
        gdown.download(url, output, quiet=False)
        print(f'Loading dataset {self.name} from npz.')
        np_obj = np.load(f'{name}.npz')
        self.images = np_obj['data']
        self.labels = np_obj['labels']
```

```

self.n_files = self.images.shape[0]
self.is_loaded = True
print(f'Done. Dataset {name} consists of {self.n_files} images.')

def image(self, i):
    # read i-th image in dataset and return it as numpy array
    if self.is_loaded:
        return self.images[i, :, :, :]

def images_seq(self, n=None):
    # sequential access to images inside dataset (is needed for testing)
    for i in range(self.n_files if not n else n):
        yield self.image(i)

def random_image_with_label(self):
    # get random image with label from dataset
    i = np.random.randint(self.n_files)
    return self.image(i), self.labels[i]

def random_batch_with_labels(self, n):
    # create random batch of images with labels (is needed for training)
    indices = np.random.choice(self.n_files, n)
    imgs = []
    for i in indices:
        img = self.image(i)
        imgs.append(self.image(i))
    logits = np.array([self.labels[i] for i in indices])
    return np.stack(imgs), logits

def image_with_label(self, i: int):
    # return i-th image with label from dataset
    return self.image(i), self.labels[i]

```

✓ Пример использования класса Dataset

Загрузим обучающий набор данных, получим произвольное изображение с меткой. После чего визуализируем изображение, выведем метку. В будущем, этот кусок кода можно закомментировать или убрать.

```

d_train_tiny = Dataset('train_tiny')

img, lbl = d_train_tiny.random_image_with_label()
print()
print(f'Got numpy array of shape {img.shape}, and label with code {lbl}.')
print(f'Label code corresponds to {TISSUE_CLASSES[lbl]} class.')

pil_img = Image.fromarray(img)
IPython.display.display(pil_img)

```

```

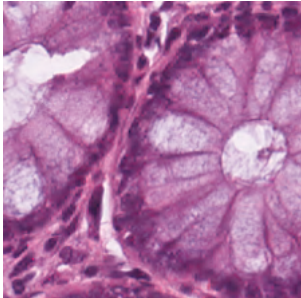
Downloading...
From: https://drive.google.com/uc?export=download&confirm=pbef&id=1I-2ZOuXLd4QwhZQ0ltp817Kn3J0Xgbui
To: C:\Users\user\DL\train_tiny.npz
100%|██████████| 105M/105M [00:34<00:00, 3.01MB/s]
Loading dataset train_tiny from npz.
Done. Dataset train_tiny consists of 900 images.

```

```

Got numpy array of shape (224, 224, 3), and label with code 6.
Label code corresponds to NORM class.

```



✓ Обёртка над Dataset для использования с PyTorch

```

# =====
# (Опционально) Обёртка над Dataset для использования с PyTorch
# =====

# ВНИМАНИЕ:
# Этот код нужен только тем, кто хочет решать задание с помощью PyTorch.

```

```
# Он показывает, как "подключить" наш Dataset к torch.utils.data.DataLoader.

try:
    import torch
    from torch.utils.data import Dataset as TorchDataset, DataLoader
    import torchvision.transforms as T
    from PIL import Image

    class HistologyTorchDataset(TorchDataset):
        """
        Обёртка над Dataset для использования с PyTorch.

        base_dataset: экземпляр Dataset('train'), Dataset('train_small'), etc.
        transform: функция/объект, преобразующий изображение (PIL.Image -> torch.Tensor).

        """
        def __init__(self, base_dataset, transform=None):
            self.base = base_dataset
            # Минимальный transform по умолчанию:
            # np.uint8 [0, 255] -> float32 [0.0, 1.0]
            self.transform = transform or T.ToTensor()

        def __len__(self):
            # Размер датасета
            return len(self.base.images)

        def __getitem__(self, idx):
            """
            Возвращает (image_tensor, label) для PyTorch.
            image_tensor: torch.Tensor формы [3, H, W]
            label: int
            """
            img, label = self.base.image_with_label(idx) # img: np.ndarray (H, W, 3)
            img = Image.fromarray(img)                  # в PIL.Image
            img = self.transform(img)                    # в torch.Tensor
            return img, label

except ImportError:
    HistologyTorchDataset = None
    print("PyTorch / torchvision не найдены. Обёртка HistologyTorchDataset недоступна.")
```

✓ Пример использования класса HistologyTorchDataset

```
if "HistologyTorchDataset" not in globals() or HistologyTorchDataset is None:
    print("PyTorch не установлен или обёртка недоступна – пример пропущен.")
else:
    print("Пример использования PyTorch-обёртки над Dataset")

    base_train = Dataset('train_tiny')

    # Создаём PyTorch-совместимый датасет
    train_ds = HistologyTorchDataset(base_train)

    # DataLoader автоматически создаёт батчи и перемешивает данные
    from torch.utils.data import DataLoader
    train_loader = DataLoader(train_ds, batch_size=8, shuffle=True)

    # Берём один батч и выводим информацию
    images_batch, labels_batch = next(iter(train_loader))

    print("Форма батча изображений:", tuple(images_batch.shape)) # [batch, 3, 224, 224]
    print("Форма батча меток:", tuple(labels_batch.shape))        # [batch]
    print("Пример меток:", labels_batch[:10].tolist())

    print("Тип images_batch:", type(images_batch))
    print("Тип labels_batch:", type(labels_batch))
```

✓ Класс Metrics

Реализует метрики точности, используемые для оценивания модели:

1. точность,
2. сбалансированную точность.

```
class Metrics:
```

```
@staticmethod
def accuracy(gt: List[int], pred: List[int]):
    assert len(gt) == len(pred), 'gt and prediction should be of equal length'
    return sum(int(i[0] == i[1]) for i in zip(gt, pred)) / len(gt)

@staticmethod
def accuracy_balanced(gt: List[int], pred: List[int]):
    return balanced_accuracy_score(gt, pred)

@staticmethod
def print_all(gt: List[int], pred: List[int], info: str):
    print(f'metrics for {info}:')
    print('\t accuracy {:.4f}'.format(Metrics.accuracy(gt, pred)))
    print('\t balanced accuracy {:.4f}'.format(Metrics.accuracy_balanced(gt, pred)))
```

Класс Model

Класс, хранящий в себе всю информацию о модели.

Вам необходимо реализовать методы `save`, `load` для сохранения и загрузки модели. Особенно актуально это будет во время тестирования на дополнительных наборах данных.

Пожалуйста, убедитесь, что сохранение и загрузка модели работает корректно. Для этого обучите модель, протестируйте, сохраните ее в файл, перезапустите среду выполнения, загрузите обученную модель из файла, вновь протестируйте ее на тестовой выборке и убедитесь в том, что получаемые метрики совпадают с полученными для тестовой выборки ранее.

Также, Вы можете реализовать дополнительные функции, такие как:

1. валидацию модели на части обучающей выборки;
2. использование кроссвалидации;
3. автоматическое сохранение модели при обучении;
4. загрузку модели с какой-то конкретной итерации обучения (если используется итеративное обучение);
5. вывод различных показателей в процессе обучения (например, значение функции потерь на каждой эпохе);
6. построение графиков, визуализирующих процесс обучения (например, график зависимости функции потерь от номера эпохи обучения);
7. автоматическое тестирование на тестовом наборе/наборах данных после каждой эпохи обучения (при использовании итеративного обучения);
8. автоматический выбор гиперпараметров модели во время обучения;
9. сохранение и визуализацию результатов тестирования;
10. Использование аугментации и других способов синтетического расширения набора данных (дополнительным плюсом будет обоснование необходимости и обоснование выбора конкретных типов аугментации)
11. и т.д.

Полный список опций и дополнений приведен в презентации с описанием задания.

При реализации дополнительных функций допускается добавление параметров в существующие методы и добавление новых методов в класс модели.

```
import torch
import torch.nn as nn
import torch.nn.functional as F
from torchvision import models
import os

from tqdm.auto import tqdm
```

```
class Model:

    def __init__(self):

        #LBL1
        self.device = torch.device("cuda" if torch.cuda.is_available() else "cpu")
        print("Device:", self.device)

        #LBL2
        self.num_classes = len(TISSUE_CLASSES)
        self.img_size = 224
        self.mean = (0.485, 0.456, 0.406)
        self.std = (0.229, 0.224, 0.225)

        #LBL3
        self.model = models.efficientnet_b0(
            num_classes=EFFICIENTNET_B0_MODEL_CLASSES,
            img_size=IMAGENET1K_MEAN_STD,
```

```

        weights=models.EfficientNet_B0_weights.IMAGENET1K_V1
    )

    #LBL4
    in_features = self.model.classifier[-1].in_features
    self.model.classifier[-1] = nn.Linear(in_features, self.num_classes)

    self.model = self.model.to(self.device)

    #LBL5
    for p in self.model.features.parameters():
        p.requires_grad = False
    for p in self.model.classifier.parameters():
        p.requires_grad = True

    #LBL6
    self.criterion = nn.CrossEntropyLoss()
    self.optimizer = torch.optim.Adam(
        filter(lambda t: t.requires_grad, self.model.parameters()), lr=1e-3
    )

    #LBL7
    self.train_tfms = T.Compose([
        T.Resize((self.img_size, self.img_size)),
        T.RandomHorizontalFlip(p=0.5),
        T.ToTensor(),
        T.Normalize(self.mean, self.std),
    ])
    self.eval_tfms = T.Compose([
        T.Resize((self.img_size, self.img_size)),
        T.ToTensor(),
        T.Normalize(self.mean, self.std),
    ])

    self.best_path = "/content/drive/MyDrive/best.pth"

#LBL8
def _numpy_to_tensor(self, img: np.ndarray) -> torch.Tensor:
    if img.ndim == 2:
        pil = Image.fromarray(img.astype(np.uint8), mode="L").convert("RGB")
    else:
        if img.dtype != np.uint8:
            img = np.clip(img, 0, 255).astype(np.uint8)
        pil = Image.fromarray(img).convert("RGB")
    x = self.eval_tfms(pil).unsqueeze(0).to(self.device, non_blocking=True) # [1,C,H,W]
    return x

#LBL9
def save(self, name: str):
    save_path = f"<u>/content/drive/MyDrive/{name}.pth</u>"
    os.makedirs(os.path.dirname(save_path), exist_ok=True)
    torch.save({
        "state_dict": self.model.state_dict(),
        "num_classes": self.num_classes,
        "img_size": self.img_size,
        "mean": self.mean,
        "std": self.std,
    }, save_path)

def load(self, name: str, strict: bool = True):

    pth_local = f"<u>/content/drive/MyDrive/{name}.pth</u>"

    #LBL10
    if not os.path.exists(pth_local):
        url = f"<u>https://drive.google.com/file/d/12yyF0kExyaCGg1IGdIIovlD0IDJBC9G5/view?usp=drive_link</u>"
        os.makedirs(os.path.dirname(pth_local), exist_ok=True)
        gdown.download(url, pth_local, quiet=False, fuzzy=True)

    #LBL11
    chkpt = torch.load(pth_local, map_location=self.device)

    #LBL12
    n_classes = int(chkpt.get("num_classes", self.num_classes))

    #LBL13
    state = chkpt.get("state_dict", chkpt)
    self.model.load_state_dict(state, strict=strict)

```

```

#LBL14
self.img_size = int(chkpt.get("img_size", self.img_size))
self.mean = tuple(chkpt.get("mean", self.mean))
self.std = tuple(chkpt.get("std", self.std))

self.train_tfms = T.Compose([
    T.Resize((self.img_size, self.img_size)),
    T.RandomHorizontalFlip(p=0.5),
    T.ToTensor(),
    T.Normalize(self.mean, self.std),
])
self.eval_tfms = T.Compose([
    T.Resize((self.img_size, self.img_size)),
    T.ToTensor(),
    T.Normalize(self.mean, self.std),
])

print(f"Loaded weights from {pth_local}")

# LBL15
def _evaluate(self, loader):
    self.model.eval()
    total_loss, total_corr, total_n = 0.0, 0, 0
    with torch.no_grad():
        for images, labels in loader:
            images = images.to(self.device, non_blocking=True)
            labels = torch.as_tensor(labels, device=self.device, dtype=torch.long)
            logits = self.model(images)
            loss = self.criterion(logits, labels)
            bs = labels.size(0)
            total_loss += loss.item() * bs
            total_corr += (logits.argmax(1) == labels).sum().item()
            total_n += bs
    avg_loss = total_loss / max(1, total_n)
    avg_acc = 100.0 * total_corr / max(1, total_n)
    return avg_loss, avg_acc

def train(self, dataset, val_dataset=None):

    print("training started")

    #LBL16
    train_ds = HistologyTorchDataset(dataset, transform=self.train_tfms)
    train_loader = DataLoader(
        train_ds, batch_size=32, shuffle=True,
        num_workers=0, pin_memory=(self.device.type == "cuda")
    )

    val_loader = None
    if val_dataset is not None:
        val_ds = HistologyTorchDataset(val_dataset, transform=self.eval_tfms)
        val_loader = DataLoader(
            val_ds, batch_size=64, shuffle=False,
            num_workers=0, pin_memory=(self.device.type == "cuda")
        )

    #LBL17
    max_epochs = 30

    #LBL18
    train_accs = []
    val_accs = []
    train_losses = []
    val_losses = []

    #LBL19
    for epoch in tqdm(range(max_epochs), total=max_epochs, desc="Epochs", position=0, leave=True):
        self.model.train()
        run_loss = 0.0
        run_corr = 0
        run_n = 0

        for images, labels in tqdm(train_loader, desc="Train", position=1, leave=False):
            images = images.to(self.device, non_blocking=True)
            labels = torch.as_tensor(labels, device=self.device, dtype=torch.long)

            #LBL20
            self.optimizer.zero_grad(set_to_none=True)
            #LBL21
            logits = self.model(images)
            #LBL22
            loss = self.criterion(logits, labels)

```

```

        #LBL23
        loss.backward()
        self.optimizer.step()

        #LBL24
        bs = labels.size(0)
        run_loss += loss.item() * bs
        run_corr += (logits.argmax(1) == labels).sum().item()
        run_n     += bs

    train_loss = run_loss / max(1, run_n)
    train_acc  = 100.0 * run_corr / max(1, run_n)

    #LBL25
    if val_loader is not None:
        val_loss, val_acc = self._evaluate(val_loader)
        #LBL26
        print(f"Epoch {epoch+1:02d}/{max_epochs} | "
              f"train_loss={train_loss:.4f} train_acc={train_acc:.2f}% | "
              f"val_loss={val_loss:.4f} val_acc={val_acc:.2f}%")
        train_losses.append(train_loss)
        val_losses.append(val_loss)
        train_accs.append(train_acc)
        val_accs.append(val_acc)
    else:
        print(f"Epoch {epoch+1:02d}/{max_epochs} | "
              f"train_loss={train_loss:.4f} train_acc={train_acc:.2f}%")

    print("training done")
    return train_losses, val_losses, train_accs, val_accs

def test_on_dataset(self, dataset, limit=None):
    predictions = []
    n = dataset.n_files if not limit else int(dataset.n_files * limit)
    for img in tqdm(dataset.images_seq(n), total=n):
        predictions.append(self.test_on_image(img))
    return predictions

#LBL27
def test_on_image(self, img: np.ndarray):
    self.model.eval()
    with torch.no_grad():
        x = self._numpy_to_tensor(img)
        logits = self.model(x)
        pred = int(logits.argmax(1).item())
    return pred

```

✎ Классификация изображений

Используя введенные выше классы можем перейти уже непосредственно к обучению модели классификации изображений. Пример общего пайплайна решения задачи приведен ниже. Вы можете его расширять и улучшать. В данном примере используются наборы данных 'train_small' и 'test_small'.

```

d_train = Dataset('train')
d_test = Dataset('test')

```

```

Done. Dataset train consists of 18000 images.
Done. Dataset test consists of 4500 images.

```

```

model = Model()
if not EVALUATE_ONLY:
    train_losses, val_losses, train_accs, val_accs = model.train(d_train, d_test)
    model.save('best')
else:
    #todo: your link goes here
    model.load('best')

```

Device: cuda
training started

Epochs: 100% 30/30 [29:24<00:00, 59.54s/it]

Epoch 01/30		train_loss=0.4461	train_acc=87.89%		val_loss=0.2017	val_acc=94.20%
Epoch 02/30		train_loss=0.2333	train_acc=92.60%		val_loss=0.1601	val_acc=95.53%
Epoch 03/30		train_loss=0.2077	train_acc=93.48%		val_loss=0.1456	val_acc=95.62%
Epoch 04/30		train_loss=0.1899	train_acc=93.99%		val_loss=0.1363	val_acc=95.93%
Epoch 05/30		train_loss=0.1820	train_acc=94.14%		val_loss=0.1699	val_acc=95.69%
Epoch 06/30		train_loss=0.1731	train_acc=94.27%		val_loss=0.1237	val_acc=96.38%
Epoch 07/30		train_loss=0.1697	train_acc=94.18%		val_loss=0.1205	val_acc=96.36%
Epoch 08/30		train_loss=0.1710	train_acc=94.49%		val_loss=0.1187	val_acc=96.29%
Epoch 09/30		train_loss=0.1665	train_acc=94.29%		val_loss=0.1291	val_acc=96.22%
Epoch 10/30		train_loss=0.1595	train_acc=94.62%		val_loss=0.1213	val_acc=96.18%
Epoch 11/30		train_loss=0.1600	train_acc=94.51%		val_loss=0.1221	val_acc=96.07%
Epoch 12/30		train_loss=0.1609	train_acc=94.59%		val_loss=0.1119	val_acc=96.31%
Epoch 13/30		train_loss=0.1528	train_acc=94.72%		val_loss=0.1163	val_acc=96.16%
Epoch 14/30		train_loss=0.1576	train_acc=94.78%		val_loss=0.1168	val_acc=96.27%
Epoch 15/30		train_loss=0.1543	train_acc=94.79%		val_loss=0.1179	val_acc=96.00%
Epoch 16/30		train_loss=0.1516	train_acc=94.86%		val_loss=0.1109	val_acc=96.58%
Epoch 17/30		train_loss=0.1581	train_acc=94.72%		val_loss=0.1137	val_acc=96.42%
Epoch 18/30		train_loss=0.1531	train_acc=94.53%		val_loss=0.1260	val_acc=95.98%
Epoch 19/30		train_loss=0.1526	train_acc=94.69%		val_loss=0.1110	val_acc=96.40%
Epoch 20/30		train_loss=0.1548	train_acc=94.80%		val_loss=0.1119	val_acc=96.42%
Epoch 21/30		train_loss=0.1488	train_acc=94.77%		val_loss=0.1106	val_acc=96.22%
Epoch 22/30		train_loss=0.1513	train_acc=94.94%		val_loss=0.1103	val_acc=96.51%
Epoch 23/30		train_loss=0.1485	train_acc=95.00%		val_loss=0.1064	val_acc=96.62%
Epoch 24/30		train_loss=0.1533	train_acc=94.79%		val_loss=0.1083	val_acc=96.42%
Epoch 25/30		train_loss=0.1521	train_acc=94.90%		val_loss=0.1086	val_acc=96.67%
Epoch 26/30		train_loss=0.1515	train_acc=94.78%		val_loss=0.1158	val_acc=96.31%
Epoch 27/30		train_loss=0.1496	train_acc=94.94%		val_loss=0.1064	val_acc=96.42%
Epoch 28/30		train_loss=0.1531	train_acc=94.71%		val_loss=0.1119	val_acc=96.58%
Epoch 29/30		train_loss=0.1482	train_acc=95.01%		val_loss=0.1118	val_acc=96.24%
Epoch 30/30		train_loss=0.1457	train_acc=94.96%		val_loss=0.1120	val_acc=96.73%

training done

```
#LBL28
import matplotlib.pyplot as plt
from datetime import datetime

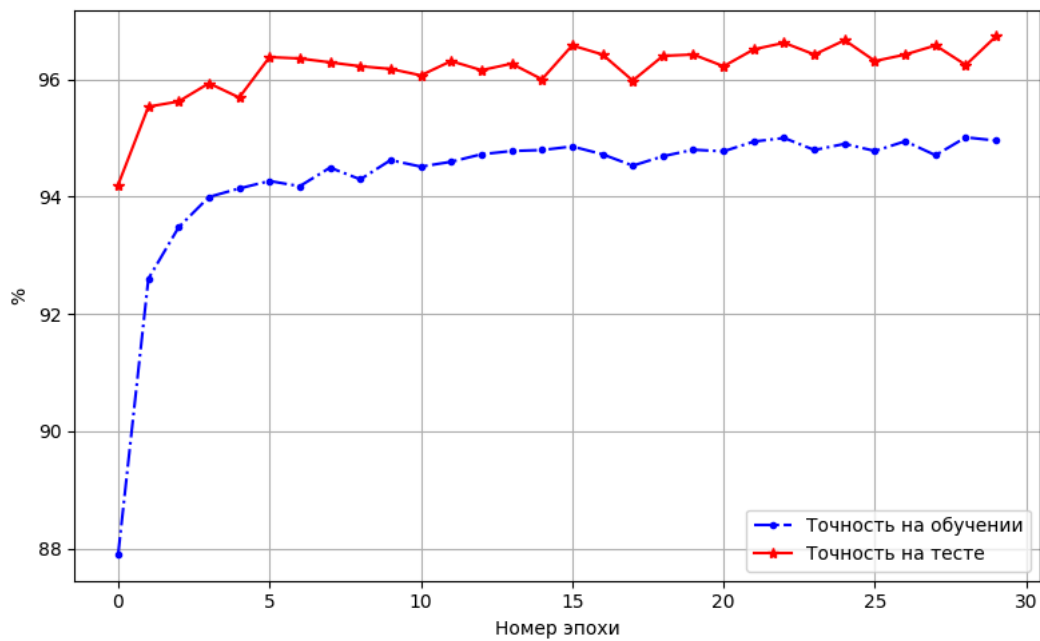
fig, ax = plt.subplots(1, 1, figsize=(8, 5))
ax.plot(train_accs, label="Точность на обучении", color='blue', marker='.', linestyle='-.')
ax.plot(val_accs, label="Точность на тесте", color='red', marker='*')

ax.set_xlabel("Номер эпохи")
ax.set_ylabel("$\\%$")

ax.grid(True)
ax.legend()

fig.text(
    0.0, 0.0, str(datetime.now()),
    fontsize=10, color='gray', alpha=0.6,
)

fig.tight_layout()
plt.show()
```



2025-11-30 07:27:59.604954

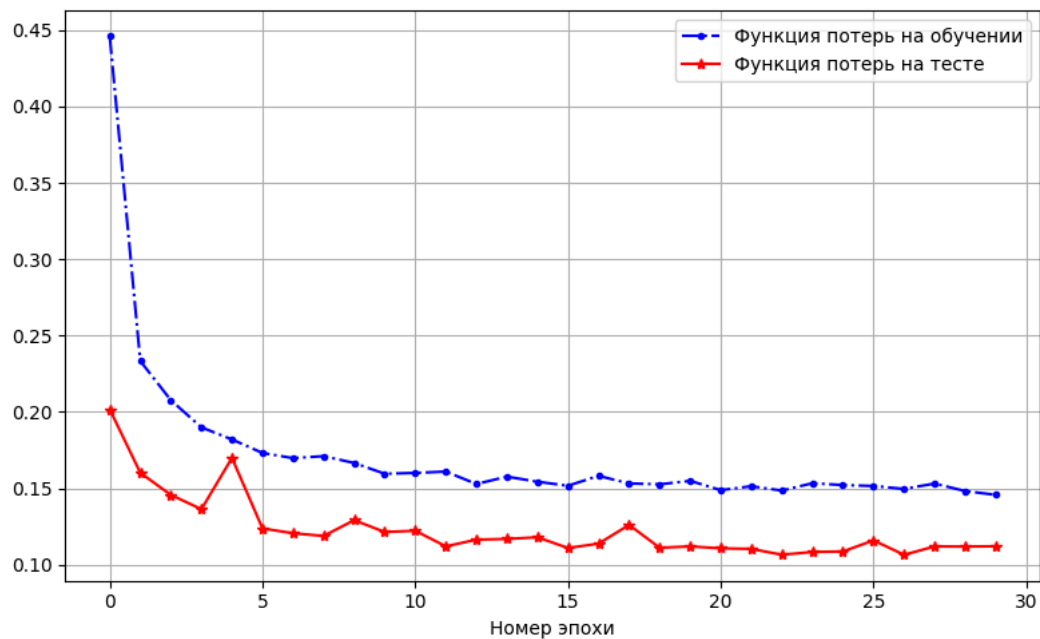
```
#LBL29
fig, ax = plt.subplots(1, 1, figsize=(8, 5))
ax.plot(train_losses, label="Функция потерь на обучении", color='blue', marker='.', linestyle='-.')
ax.plot(val_losses, label="Функция потерь на тесте", color='red', marker='*')

ax.set_xlabel("Номер эпохи")

ax.grid(True)
ax.legend()

fig.text(
    0.0, 0.0, str(datetime.now()),
    fontsize=10, color='gray', alpha=0.6,
)

fig.tight_layout()
plt.show()
```



2025-11-30 07:30:36.451679

EVALUATE_ONLY = True

```
model = Model()
model.load('best')
```

Device: cuda
Loaded weights from /content/drive/MyDrive/best.pth

Пример тестирования модели на части набора данных:

```
# evaluating model on 10% of test dataset
pred_1 = model.test_on_dataset(d_test, limit=0.1)
Metrics.print_all(d_test.labels[:len(pred_1)], pred_1, '10% of test')
```

100% 450/450 [00:04<00:00, 100.16it/s]

metrics for 10% of test:
accuracy 0.9978:
balanced accuracy 0.9978:
/usr/local/lib/python3.12/dist-packages/sklearn/metrics/_classification.py:2524: UserWarning: y_pred contains classes not in y_true
warnings.warn("y_pred contains classes not in y_true")

Пример тестирования модели на полном наборе данных:

```
# evaluating model on full test dataset (may take time)
if TEST_ON_LARGE_DATASET:
    pred_2 = model.test_on_dataset(d_test)
    Metrics.print_all(d_test.labels, pred_2, 'test')
```

100% 4500/4500 [00:55<00:00, 40.81it/s]

metrics for test:
accuracy 0.9673:
balanced accuracy 0.9673:

Результат работы пайплайна обучения и тестирования выше тоже будет оцениваться. Поэтому не забудьте присылать на проверку ноутбук с выполненными ячейками кода с демонстрациями метрик обучения, графиками и т.п. В этом пайплайне Вам необходимо продемонстрировать работу всех реализованных дополнений, улучшений и т.п.

Настоятельно рекомендуется после получения пайплайна с полными результатами обучения экспортировать ноутбук в pdf (файл -> печать) и прислать этот pdf вместе с самим ноутбуком.

✓ Тестирование модели на других наборах данных

Ваша модель должна поддерживать тестирование на других наборах данных. Для удобства, Вам предоставляется набор данных test_tiny, который представляет собой малую часть (2% изображений) набора test. Ниже приведен фрагмент кода, который будет осуществлять тестирование для оценивания Вашей модели на дополнительных тестовых наборах данных.

Прежде чем отсылать задание на проверку, убедитесь в работоспособности фрагмента кода ниже.

```
final_model = Model()
final_model.load('best')
d_test_tiny = Dataset('test_tiny')
pred = final_model.test_on_dataset(d_test_tiny)
Metrics.print_all(d_test_tiny.labels, pred, 'test-tiny')
```

Device: cuda
Loaded weights from /content/drive/MyDrive/best.pth
Done. Dataset test_tiny consists of 90 images.

100% 90/90 [00:01<00:00, 94.33it/s]

metrics for test-tiny:
accuracy 0.9778:
balanced accuracy 0.9778:

Отмонтировать Google Drive.

```
drive.flush_and_unmount()
```

✓ Дополнительные "полезности"

Ниже приведены примеры использования различных функций и библиотек, которые могут быть полезны при выполнении данного практического задания.

✓ Измерение времени работы кода

Измерять время работы какой-либо функции можно легко и непринужденно при помощи функции timeit из соответствующего модуля:

```

import timeit

def factorial(n):
    res = 1
    for i in range(1, n + 1):
        res *= i
    return res

def f():
    return factorial(n=1000)

n_runs = 128
print(f'Function f is calculated {n_runs} times in {timeit.timeit(f, number=n_runs)}s.')

```

✓ Scikit-learn

Для использования "классических" алгоритмов машинного обучения рекомендуется использовать библиотеку scikit-learn (<https://scikit-learn.org/stable/>). Пример классификации изображений цифр из набора данных MNIST при помощи классификатора SVM:

```

# Standard scientific Python imports
import matplotlib.pyplot as plt

# Import datasets, classifiers and performance metrics
from sklearn import datasets, svm, metrics
from sklearn.metrics import ConfusionMatrixDisplay
from sklearn.model_selection import train_test_split

# The digits dataset
digits = datasets.load_digits()

# The data that we are interested in is made of 8x8 images of digits, let's
# have a look at the first 4 images, stored in the `images` attribute of the
# dataset. If we were working from image files, we could load them using
# matplotlib.pyplot.imread. Note that each image must have the same size. For these
# images, we know which digit they represent: it is given in the 'target' of
# the dataset.
_, axes = plt.subplots(2, 4)
images_and_labels = list(zip(digits.images, digits.target))
for ax, (image, label) in zip(axes[0, :], images_and_labels[:4]):
    ax.set_axis_off()
    ax.imshow(image, cmap=plt.cm.gray_r, interpolation='nearest')
    ax.set_title('Training: %i' % label)

# To apply a classifier on this data, we need to flatten the image, to
# turn the data in a (samples, feature) matrix:
n_samples = len(digits.images)
data = digits.images.reshape((n_samples, -1))

# Create a classifier: a support vector classifier
classifier = svm.SVC(gamma=0.001)

# Split data into train and test subsets
X_train, X_test, y_train, y_test = train_test_split(
    data, digits.target, test_size=0.5, shuffle=False)

# We learn the digits on the first half of the digits
classifier.fit(X_train, y_train)

# Now predict the value of the digit on the second half:
predicted = classifier.predict(X_test)

images_and_predictions = list(zip(digits.images[n_samples // 2:], predicted))
for ax, (image, prediction) in zip(axes[1, :], images_and_predictions[:4]):
    ax.set_axis_off()
    ax.imshow(image, cmap=plt.cm.gray_r, interpolation='nearest')
    ax.set_title('Prediction: %i' % prediction)

print("Classification report for classifier %s:\n%s\n"
      % (classifier, metrics.classification_report(y_test, predicted)))

# Матрица ошибок + визуализация в новом API
cm = metrics.confusion_matrix(y_test, predicted)
disp = ConfusionMatrixDisplay(confusion_matrix=cm,
                              display_labels=classifier.classes_)

fig, ax = plt.subplots(figsize=(4, 4))
disp.plot(ax=ax)

```

```
ax.set_title("Confusion Matrix")
plt.tight_layout()
plt.show()
```

✓ Scikit-image

Реализовывать различные операции для работы с изображениями можно как самостоятельно, работая с массивами numpy, так и используя специализированные библиотеки, например, scikit-image (<https://scikit-image.org/>). Ниже приведен пример использования Canny edge detector.

```
import numpy as np
import matplotlib.pyplot as plt
from scipy import ndimage as ndi

from skimage import feature

# Generate noisy image of a square
im = np.zeros((128, 128))
im[32:-32, 32:-32] = 1

im = ndi.rotate(im, 15, mode='constant')
im = ndi.gaussian_filter(im, 4)
im += 0.2 * np.random.random(im.shape)

# Compute the Canny filter for two values of sigma
edges1 = feature.canny(im)
edges2 = feature.canny(im, sigma=3)

# display results
fig, (ax1, ax2, ax3) = plt.subplots(nrows=1, ncols=3, figsize=(8, 3),
                                    sharex=True, sharey=True)

ax1.imshow(im, cmap=plt.cm.gray)
ax1.axis('off')
ax1.set_title('noisy image', fontsize=20)

ax2.imshow(edges1, cmap=plt.cm.gray)
ax2.axis('off')
ax2.set_title(r'Canny filter, $\sigma=1$', fontsize=20)

ax3.imshow(edges2, cmap=plt.cm.gray)
ax3.axis('off')
ax3.set_title(r'Canny filter, $\sigma=3$', fontsize=20)

fig.tight_layout()

plt.show()
```

✓ Tensorflow 2

Для создания и обучения нейросетевых моделей можно использовать фреймворк глубокого обучения Tensorflow 2. Ниже приведен пример простейшей нейронной сети, использующейся для классификации изображений из набора данных MNIST.

```
# Install TensorFlow

import tensorflow as tf

mnist = tf.keras.datasets.mnist

(x_train, y_train), (x_test, y_test) = mnist.load_data()
x_train, x_test = x_train / 255.0, x_test / 255.0

model = tf.keras.models.Sequential([
    tf.keras.layers.Flatten(input_shape=(28, 28)),
    tf.keras.layers.Dense(128, activation='relu'),
    tf.keras.layers.Dropout(0.2),
    tf.keras.layers.Dense(10, activation='softmax')
])

model.compile(optimizer='adam',
              loss='sparse_categorical_crossentropy',
              metrics=['accuracy'])

model.fit(x_train, y_train, epochs=5)

model.evaluate(x_test, y_test, verbose=2)
```

Для эффективной работы с моделями глубокого обучения убедитесь в том, что в текущей среде Google Colab используется аппаратный ускоритель GPU или TPU. Для смены среды выберите "среда выполнения" -> "сменить среду выполнения".

Большое количество tutorиалов и примеров с кодом на TensorFlow 2 можно найти на официальном сайте <https://www.tensorflow.org/tutorials?hl=ru>.

Также, Вам может понадобиться написать собственный генератор данных для TensorFlow 2. Скорее всего он будет достаточно простым, и его легко можно будет реализовать, используя официальную документацию TensorFlow 2. Но, на всякий случай (если не удалось сразу разобраться или хочется вникнуть в тему более глубоко), можете посмотреть следующий отличный tutorиал: <https://stanford.edu/~shervine/blog/keras-how-to-generate-data-on-the-fly>.

PyTorch

```
# =====
# Дополнительно: мини-демо PyTorch
# =====
# Ранний выход, если PyTorch/обёртка недоступны
try:
    import torch
    import torch.nn as nn
    import torch.nn.functional as F
    from torch.utils.data import DataLoader
except ImportError:
    print("PyTorch не установлен – демо пропущено.")
    import sys
    raise SystemExit

if "HistologyTorchDataset" not in globals() or HistologyTorchDataset is None:
    print("HistologyTorchDataset недоступна – демо пропущено.")
    import sys
    raise SystemExit

# --- Данные: tiny-наборы, чтобы выполнялось быстро ---
base_train = Dataset('train_tiny')
base_test = Dataset('test_tiny')

train_ds = HistologyTorchDataset(base_train)          # ToTensor по умолчанию
test_ds = HistologyTorchDataset(base_test)

train_loader = DataLoader(train_ds, batch_size=16, shuffle=True)
test_loader = DataLoader(test_ds, batch_size=32, shuffle=False)

# --- Мини-модель: двухслойный CNN + один FC (демонстрация, не решение) ---
class TinyCNN(nn.Module):
    def __init__(self, num_classes=len(TISSUE_CLASSES)):
        super().__init__()
        self.conv1 = nn.Conv2d(3, 8, kernel_size=3, padding=1)
        self.conv2 = nn.Conv2d(8, 16, kernel_size=3, padding=1)
        self.pool = nn.MaxPool2d(2, 2) # 224->112->56
        self.fc = nn.Linear(16 * 56 * 56, num_classes)

    def forward(self, x):
```

```

        x = self.pool(F.relu(self.conv1(x))) # [B, 3, 224, 224] -> [B, 8, 112, 112]
        x = self.pool(F.relu(self.conv2(x))) # [B, 8, 112, 112] -> [B, 16, 56, 56]
        x = x.view(x.size(0), -1)
        x = self.fc(x)
        return x

device = torch.device("cuda" if torch.cuda.is_available() else "cpu")
print("Device:", device)

model = TinyCNN(num_classes=len(TISSUE_CLASSES)).to(device)
criterion = nn.CrossEntropyLoss()
optimizer = torch.optim.Adam(model.parameters(), lr=1e-3)

# --- Один учебный шаг "обучения" на одном батче ---
model.train()
xb, yb = next(iter(train_loader))
xb = xb.to(device)
yb = yb.to(device, dtype=torch.long)

optimizer.zero_grad()
logits = model(xb)
loss = criterion(logits, yb)
float_loss = float(loss.detach().cpu())
loss.backward()
optimizer.step()

print(f"Loss на одном батче train_tiny: {float_loss:.4f}")

# --- Быстрая проверка на одном батче теста (для формы вывода/метрик) ---
model.eval()
with torch.no_grad():
    xt, yt = next(iter(test_loader))
    xt = xt.to(device)
    logits_t = model(xt).cpu()
    y_pred = logits_t.argmax(dim=1).numpy()
    y_true = yt.numpy()

print("Размерности:", {"y_true": y_true.shape, "y_pred": y_pred.shape})
Metrics.print_all(y_true, y_pred, "_") # balanced accuracy/accuracy на одном батче для демонстрации

# для полноценного решения требуется собственный тренировочный цикл по эпохам,
..

```

Дополнительные ресурсы по PyTorch

- **Официальные туториалы PyTorch** — <https://pytorch.org/tutorials/>
- **“Deep Learning with PyTorch: 60-Minute Blitz”** — https://pytorch.org/tutorials/beginner/deep_learning_60min_blitz.html
- **Transfer Learning for Computer Vision** — https://pytorch.org/tutorials/beginner/transfer_learning_tutorial.html
- **PyTorch Get Started (установка)** — <https://pytorch.org/get-started/locally/>
- **Dive into Deep Learning (D2L, глава PyTorch)** — https://d2l.ai/chapter_preliminaries/index.html
- **Fast.ai — Practical Deep Learning for Coders** — <https://course.fast.ai/>
- **Learn PyTorch.io (Zero to Mastery)** — <https://www.learnpytorch.io/>

Numba

В некоторых ситуациях, при ручных реализациях графовых алгоритмов, выполнение многократных вложенных циклов for в python можно существенно ускорить, используя JIT-компилятор Numba (<https://numba.pydata.org/>). Примеры использования Numba в Google Colab можно найти тут:

1. https://colab.research.google.com/github/cbernet/maldives/blob/master/numba/numba_cuda.ipynb
2. https://colab.research.google.com/github/evaneschneider/parallel-programming/blob/master/COMPASS_gpu_intro.ipynb

Пожалуйста, если Вы решили использовать Numba для решения этого практического задания, еще раз подумайте, нужно ли это Вам, и есть ли возможность реализовать требуемую функциональность иным способом. Используйте Numba только при реальной необходимости.